Bioinformática 2026

TP Nº2: Alineamiento de secuencias y BLAST

Objetivo general: Familiarizarse con BLAST (web-ncbi) y con la versión de línea de comando.

Introducción:

El algoritmo BLAST (Basic Local Alignment Search Tool) permite realizar búsquedas rápidas de secuencias sobre bases de datos biológicas (de secuencias). Esto lo hace mediante una heurística, la cual consiste en generar pequeñas secuencias semilla a partir de la consulta inicial, alinearlas contra cada una de las secuencias en la base de datos e ir extendiendo en medida que las correspondencias tengan un elevado score. Llamaremos query a la secuencia que se quiere buscar y db a la base sobre la cual se realiza dicha búsqueda. La eficiencia del método está en evitar la comparación exhaustiva entre el query entero y la base de datos, sino que compara los pequeños fragmentos o words y luego extiende los matchs hasta que logren superar un umbral determinado.

BLAST en realidad son 4 algoritmos:

blastn (query -> nu db -> nu)
blastp (query -> prot db -> prot)
blastx (query -> nucleótido , db -> prot)
tblastn (query -> prot, db -> nucl).

Los resultados son las correspondencias de la query con una dada entrada de la db, a la que llamaremos **hit**, métricas de esa correspondencia (identidad, cobertura, gaps) y dependiendo de lo solicitado, el alineamiento entre las mismas.

Objetivo 1: Uso de BLAST en NCBI-web.

Objetivo 1.1 Comparación de 2 secuencias

Vaya a la página de BLAST (http://blast.ncbi.nlm.nih.gov/Blast.cgi). Para realizar una

comparación entre dos secuencias proteicas, haga click en el icono PROTEIN BLAST y luego en la página emergente seleccione la opción “Align two or more sequences”. De esta manera se accede al formulario de comparación de secuencias, en el mismo se pueden elegir los diferentes parámetros del alineamiento, como ser:

- Distintos tipos de alineamientos BLAST: blastn, blastp, blastx, tblastn y tblastx. ¿Qué opciones de programas hay y para qué tipo de comparaciones sirven?
- Los parámetros para el alineamiento. Deje los valores por defecto con la Matriz BLOSUM62. ¿Qué otras matrices hay disponibles? ¿Conoce sus diferencias?
- Los valores de “gap costs” *(existence* y *extension*). ¿Qué particularidad tienen? ¿A qué se debe?

Para comparar dos secuencias, ambas deben ser pegadas en formato fasta, y luego se debe hacer click en el link BLAST (abajo a la izquierda). Con esto el programa realizará el alineamiento y se abrirá la página de resultados.

Ejercicio 1.1:

Busque en Uniprot la secuencia de 2 a 3 mioglobinas de otros organismos y comparelas con la de humano (la tiene del TP anterior) utilizando la versión web de BLAST. Analice los resultados y responda las siguientes preguntas:

i) ¿El alineamiento abarca la secuencia completa de las 2 proteínas? ¿Le parece que es un alineamiento local o global? Justifique

ii) ¿Se observan gaps en el dot-plot? ¿Cuántos? ¿Cómo se identifican?

iii) Analice el resultado del alineamiento en general tomando en cuenta los valores obtenidos de “Score”, “E value”, “Identities”, “Positives” y “Gaps”.

Pruebe cómo varían los resultados del alineamiento anterior modificando los siguientes parámetros: a) Utilizando la Matriz Blosum-80, b) Utilizando un costo de Gap existence y Gap extension: 11:2, c) Utilizando un costo de Gap existence y Gap extension: 9:1.

¿Qué cambios se observan para cada caso?

Interprete los resultados en base a lo que sabe sobre las diferencias entre las matrices de sustitución. Analice si existen diferencias en los alineamientos y cambios en los valores de Score (raw Alignment score) “puntaje crudo del alineamiento” que figura entre paréntesis

Objetivo 1.2

Utilización de BLAST para la búsqueda en bases de datos. Búsqueda de proteínas homólogas a la mioglobina (Mb) en humanos. El objetivo de esta sección es buscar todas las proteínas homólogas a la Mb humana que han sido caracterizadas en humanos.

Vaya a la página de BLAST (http://blast.ncbi.nlm.nih.gov/Blast.cgi). El primer paso es seleccionar el programa a utilizar “Protein BLAST” que es para comparar proteínas (o sea Protein-Protein BLAST). Usted accede ahora a la página donde ingresará los datos de la búsqueda. Seleccione la base de datos que usará para buscar secuencias parecidas a la suya. Seleccione por ejemplo *Non-redundant*.

La secuencia query de la Mb con la cual realizaremos la búsqueda puede ser ingresada de dos maneras, 1) utilizando el *accesion number/Gene bank identifier* o 2) ingresando la secuencia en formato FASTA.

Una de las ventajas de hacer BLAST en NCBI es que se puede restringir la búsqueda fácilmente a uno (o un grupo) de organismos deseados. Para esto se eligen los organismos directamente de una lista o se escribe el nombre del mismo (o clase taxonómica). Seleccione Organism: Human (aparece al comenzar a tipear).

El resto de los parámetros que se pueden modificar alteran los parámetros de la búsqueda y solamente se ajustan en casos especiales.

Análisis de resultados

La página de resultados de BLAST mostrará 3 secciones principales.

- Descriptions: Ranking de las proteínas encontradas junto con su nombre, score, e-value, étc. para cada resultado.

- Graphic Summary: Muestras los resultados en formato gráfico

- Alignments: Muestra el alineamiento de a pares de la proteína Query con las proteínas de la Base de Datos. Puede acceder a estos alineamientos también a través del resultado gráfico, haciendo click con el mouse sobre las barras de colores que simbolizan cada uno de los alineamientos referidos.

Ejercicio 1.2 Análisis de resultados (Responda).

i) Al observar los resultados notarán que hay muchos resultados repetidos o inútiles (la Mb aparece muchas veces y muchas proteínas aparecen cada vez que fueron cristalizadas) ¿Cómo mejoraría la búsqueda para obtener realmente solo aquellas homólogas a la Mb una sola vez?

=> Repita la búsqueda usando como base de datos RefSeq

ii) Describa brevemente cada una de las proteínas homólogas encontrada. Compare los E-values, los scores y los alineamientos obtenidos.

iii) ¿Cuál es la globina humana más parecida a la Mioglobina? ¿Le sorprende alguno de los resultados?

iv) ¿Usted cree que encontró todas las proteínas de la familia de las globinas que existen en el genoma humano?

v) Intente encontrar la mayor cantidad de globinas existentes en el genoma humano modificando los parámetros de búsqueda de BLASTp (matriz, costo de gaps, word size, etc.). Indique qué parámetros modificó y qué nuevas proteínas encontró significativamente parecidas a la mioglobina.

vi) Una manera de buscar secuencias homólogas más distantes en la escala evolutiva usando PSI-BLAST. Vuelva a la página de parámetros de la búsqueda, y usando la secuencia de Mb como query realice una nueva búsqueda, pero usando como algoritmo PSI-BLAST. Analice los resultados obtenidos. ¿Encontraron alguna proteína que no había aparecido antes ? ¿Cuántas iteraciones realizaron ?

Nota: Luego de elegir PSI-BLAST debe comenzar a hacer iteraciones. Por lo menos 1 es necesaria para que se calcule la PSSM y realice la nueva búsqueda. Revise que el programa elija las proteínas correctas (las que usted ya encontró) para la próxima iteración y corra una segunda iteración de PSI-BLAST.

Objetivo 2: Uso de BLAST en línea de comando.

2.1) Instale blast con el comando “sudo apt install ncbi-blast+” o también, si tiene levantado un ambiente de conda, puede hacer “conda install -c bioconda blast”

En este punto, usted quizá se preguntará: ¿Por qué usar una ejecución local de blast si hay tantos buscadores de secuencia en la web (como el que usamos antes)?

En general, si queremos buscar secuencias de a una, o analizar un resultado corto, es siempre mejor usar una herramienta online. Pero si queremos buscar en **muchas muestras**, con muchos parámetros distintos, en bases distintas a las que ofrecen las distintas páginas, o dentro de un pipeline de análisis más complejo, conviene correr las búsquedas localmente.

Blast ofrece varios formatos de salida, pero aquí marcaremos los 2 más utilizados: a) separado por tab (tsv), b) salida de texto.

La primera es muy útil para analizarla con la librería *pandas* y permite elegir las columnas del archivo (incluso se puede pedir el alineamiento, cosa que no hace por defecto). La salida de texto es la más tradicional y su objetivo es que pueda ser comprendida por una persona. Por otro lado, casi todos los formatos se pueden leer usando Biopython, cosa que veremos al final de la práctica.

Lo que haremos ahora es descargar unos archivos a nuestro disco local y trabajar con BLAST sobre los mismos a modo de ejemplo:

2.2) Descargue y Pruebe buscar las secuencias de 3 proteínas: drra , map2k7 y ndk sobre la base de datos vfdbB.

La **Virulence Factor Database (VFDB)** es un repositorio curado que recopila factores de virulencia bacterianos (genes y proteínas) validados mediante experimentos científicos. Organiza esta información en categorías funcionales —como toxinas, sistemas de secreción y factores de adherencia— para explicar cómo los patógenos logran infectar y evadir defensas. Es la herramienta estándar en bioinformática para predecir el potencial infeccioso de bacterias desconocidas comparando sus secuencias contra este catálogo de "armas" biológicas.

> **drrA:** Es un componente esencial de transportadores tipo ABC que facilita la resistencia a antibióticos mediante el bombeo activo de fármacos hacia afuera de la célula. En micobacterias, juega un rol crucial en el transporte de lípidos necesarios para la estructura y virulencia de la pared celular.
>
> **map2k7:** Una quinasa de especificidad dual que actúa como un interruptor

clave en la vía de señalización JNK, respondiendo principalmente a estímulos de estrés ambiental. Regula procesos vitales como la inflamación, la diferenciación celular y la muerte programada (apoptosis) en organismos complejos.

ndk (Nucleósido Difosfato Quinasa): Enzima encargada de mantener el equilibrio de los niveles de nucleótidos (como el ATP) mediante la transferencia de grupos fosfato entre moléculas. Actúa además como un factor de virulencia que bloquea la maduración del fagosoma, permitiendo que patógenos sobrevivan dentro de las células del sistema inmune.

Descargamos los archivos de uniprot

wget -O drrA.faa "https://rest.uniprot.org/uniprotkb/Q29ST3.fasta"

(Baje ud las otras dos, revise los fasta correspondientes.)

Descargamos la base de datos:

wget "http://www.mgc.ac.cn/VFs/Down/VFDB_setB_pro.fas.gz"

Descomprimimos el archivo:

gunzip VFDB_setB_pro.fas.gz

Visualice (en formato texto) la base de datos, ¿Qué tipo de archivo es y cómo guarda la información?

Ahora para que BLAST funcione, generamos el índice:

makeblastdb -dbtype prot -in VFDB_setB_pro.fas

Finalmente, realizamos la búsqueda de drra:

blastp -query drrA.faa -db VFDB_setB_pro.fas -evalue 1e-5

Nota: Aquí tiene una guia de todos los parámetros de blast, sin embargo, los más útiles suelen ser:

-num_threads, para indicar la cantidad de núcleos a utilizar (si desea paralelizar),

-qcov_hsp_perc, para indicar la cobertura mínima de la query,

-evalue, para limitar los hits, ya que su valor por defecto es 10 y suele traer mucha

basura

-outfmt, para modificar el formato del output.

Ejercicio 2.1: Repita la misma búsqueda con el parámetro -outfmt 6 y visualice las columnas. Investigue en este link como incluir el alineamiento en las columnas. Repita lo mismo para las otras 2 proteínas. ¿Qué puede concluir del análisis?

Ahora, vamos a procesar la salida de Blast utilizando el paquete Bio.SearchIO de la librería Biopython (que usted ya utilizó previamente). Para entender las estructuras de datos que genera Biopython al leer los hits, **lea** detenidamente la seccion de BLAST de este link (la misma estructura es utilizada para Hmmer, y lo veremos en la próxima guía).

Ejercicio 2.2: Como ejercicio, vamos a buscar TODOS los factores de virulencia de la base de datos VFDB sobre el proteoma de Staphylococcus aureus N315. Baje el proteoma en formato fasta y ejecuté Blast, usando el formato de salida xml o el formato tabular (investigue qué -outfmt usar en cada caso), pidiendo una cobertura del hit del 70% (investigue el parámetro indicado) y almacenando el resultado en un archivo.

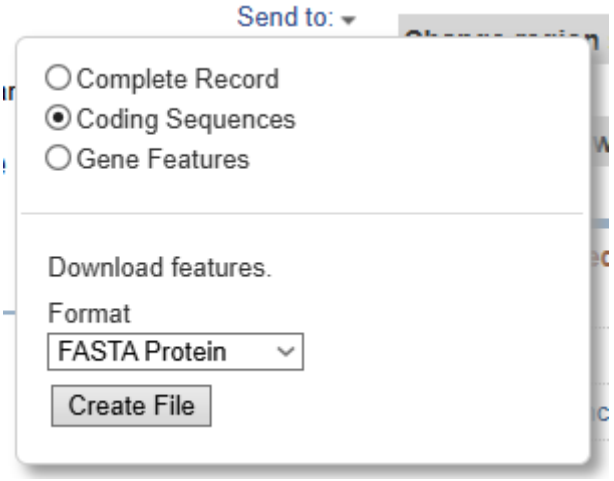

Para analizar el resultado, complete el script (o código de python) a partir del que mostramos más abajo, para generar una tabla que muestre las siguientes columnas: query, hit, cobertura de la query, cobertura del hit, identidad y de qué especie es la proteína hit (donde “busqueda.blast” debe ser el resultado de la búsqueda anterior).

```
import Bio.SearchIO as bpio
resultados=list(bpio.parse('busqueda.blast', 'blast-xxx')) # donde xxx es xml o tab
for query_result in resultados:
    ###### Pseudo codigo ############################
Iterar hits (armar un bucle con FOR en la seccion de hits)
        Iterar hsps (armar un bucle con FOR en la seccion de hsps)
    ##############################################
```

Es muy común encontrarse con familias de proteínas que poseen funciones mal anotadas (por ejemplo, el nombre de un gen) y/o representantes cuyas secuencias no son muy distintas, pero a la hora de anotar un genoma, es importante distinguir entre las mismas. Puede usar el output de blast que quiera, pero recomendamos el formato de tabla. Como ejemplo de esto, vamos a usar el ejemplo de las enterotoxinas, una familia de proteínas que en nuestra experiencia está bastante mal anotada en las bases secundarias. En este trabajo, hacen un buen trabajo curando secuencias representativas de cada toxina, con lo cual, cuando vemos “buenos hits” de nuestros genes contra ellas, podemos estar seguros de su clasificación. Las secuencias curadas pueden encontrarlas en este link, que posee la BD de enterotoxinas.

Ejercicios 2.3:

a) Realice un blast del proteoma de N315 contra la base de enterotoxinas y desarrolle un script que levantando esa información indique cuáles son las enterotoxinas que posee (o sea están presentes en) el proteoma. (Posiblemente obtenga varios hits para cada proteína)

b) Programe algún criterio de decisión en función de la identidad/cobertura. En caso de que más de un hit cumpla las expectativas, indique que encontró más de una proteína.