

Introducción a la Bioinformática Molecular.

Trabajo Práctico 3

Ángel Nicolás Gauto

Manel Montalat

Ejercicio 1 – Dominios en Conserved domains

1a) Utilizamos blastp ya que estamos trabajando con proteínas, y la base de datos refseq_select ya que tiene datos no redundantes e ignora las isoformas. Observamos que la gran mayoría de los hits son mayormente hemoproteínas con dominios heme NO-binding domain-containing, que es la proteína query pero en otras especies de *Clostridium*. También aparece en otras especies similares. Su grupo prostético es hemo, el cual une moléculas de óxido nítrico y su función es la misma que la descrita en el TP.

2a) Las de *C. tetani* están muy poco conservadas, ya que no alcanzan el 40% de identidad y la cobertura es menor al 50%. Aparecen proteínas homólogas en miembros de la familia *Haloimpatiens*, *Inconstantimicrobium mannanitabidum*, *Desnuesiella massiliensis*, *Vallitalea okinawensis* y otros, ya que tienen una identidad entre 60 y 50%, con una cobertura de 97% y un e-value de 0.

1b) Presenta 2 dominios, las HNOB (heme NO-binding) y Tar. El primero proviene de PFAM del NCBI, es un dominio sensor, une hemo y detecta óxido nítrico, su función es contener al grupo prostético hemo, detectar óxido nítrico y participar en señalización/redox, esta presente en animales y bacterias. El segundo proviene de la base de datos COG del NCBI y su función es ser un sensor ambiental, detectando sustancias químicas en el entorno para enviar una señal al interior de la bacteria y de esta manera promover una respuesta frente al ambiente.

Ejercicio 2 – InterPro y PFAM

2a) Aparecen dominios como:

* HNOB / Heme NO-binding domain: proveniente de la base de datos Pfam (PF07700). Este dominio corresponde a proteínas capaces de unir un grupo hemo y detectar moléculas gaseosas como NO (óxido nítrico).

* H-NOX domain superfamily, identificado por CATH-Gene3D, relacionado estructuralmente con dominios sensores de gases.

* NO signalling/Golgi transport ligand-binding domain superfamily, identificado por SUPERFAMILY/SSF, también asociado a unión de ligandos gaseosos.

* Un dominio relacionado con Methyl-accepting chemotaxis proteins (MCPs), asociado a proteínas de transducción de señales y quimiotaxis bacteriana.

2b) Esperamos que se conserve la histidina ya que actúa como ligando del hemo.

2c) Efectivamente, se puede observar que la histidina se encuentra alineada en todas las secuencias de la columna 137, por lo que este aminoácido se encuentra conservado entre los distintas secuencias analizadas.

2d) Otros aminoácidos conservados son la arginina en la columna 175, la glicina en la 2 y la prolina en la 154. Se conservan ligeramente el aspartato en la 138 y la glicina en la 115. Hay una inserción alrededor de la columna 116, y otra en la 140.

2e) Como el logo no toma en cuenta las inserciones por la cantidad de gaps, muchas de las columnas están en posiciones anteriores a las anotadas en el ítem anterior. Las posiciones mas importantes son la 2 (glicina), 41 (tirosina, valina), 69 (glicina), 81 (tirosina, fenilalanina), 95 (fenilalanina, leucina), 103 (histidina), 116 (prolina), 132 (tirosina), 134 (serina), 136 (arginina, lisina), 145 (glicina), y 154 (fenilalanina, tirosina). Los porcentajes de inserción son 44% en la columna 31, 41% en la columna 103 y 37% en la columna 152.

2f) La histidina conservada del ejercicio 2b está en la posición 103 según el logo. Representa una ocupación muy alta (aprox 0,995) indicando que esta presente en casi todas las secuencias del alineamiento, además que la H tiene una probabilidad muy elevada dentro de la columna.

2g) En el texto, se observa que la histidina en la posición 103 tiene una de las probabilidades mas bajas de ser emitida en un match, que es lo opuesto a lo que esperábamos. La arginina conservada también es la de menor probabilidades, lo mismo pasa con la prolina y la glicina. Lo que interpretamos es que como en el Pfam/HMMER los valores son scores transformados (log-odds), los números mas pequeños son aminoácidos mas favorecidos o conservados, por lo que si la histidina en esta posición tiene un 0,22 significa que es muy probable que este lugar sea ocupado por una histidina, y entonces estaría fuertemente conservada en esta posición.

2h) Se puede combinar con HNOB se muestran como “barras de colores” cercanos al dominio, estos son: MCPsignal, guanilato_cyc, HNOBA, PAS_9, PAS_4 , PDEase_I entre otras.

2i) Hay 116 especies de Clostridium, y tiene 153 secuencias. Otras especies de Clostridium que tienen el dominio HNOB son Botulinum, Perfringens, Beijerinckii, Sporogenes y Kluverii entre otros.

2j) El dominio MCPsignal puede combinarse con otros dominios como HAMP, Tar3, 4HB_MCP₁ y PAS_3. Los aminoácidos conservados son la glutamina en la columna 48, asparagina en la columna 50 y 55, arginina en la columna 62, glicina en las columnas 64, 67 y 69, fenilalanina en la columna 70, glutamato en la columna 76 y leucina en la columna 80. Su función es transducir señales a ChoA (proteína quinasa) la cual es fundamental en la quimiotaxis bacteriana, por lo que se halla principalmente en bacterias.

Ejercicio 3 – Prosite y Patrones

3a) El signature que se halla es R-T-E-[EQ]-Q-x(2)-[SA]-[LIVM]-x-[EQ]-T-A-A-S-M-E-Q-L-T-A-T-V, por lo tanto es un patrón con expresiones regulares en vez de una matriz con probabilidades.

En el logo se puede observar que no hay ninguna histidina conservada, así podemos descartar que pertenezca a HNOB, y como la descripción habla sobre transducción de señales químicas y methyl-accepting sites, concluimos que el dominio al que pertenece es MCPsignal.

3b) Viendo el logo desde la columna 130, decidimos ingresar el patrón [LIM]-x-Y-x-S-x-R-x(2)-[LMF]. Aparecen múltiples proteínas del African swine fever virus, la proteína Lysosomal cobalamin transporter ABCD4 en humano y ratón, múltiples proteínas del arroz, entre otras.

3c) Los patrones antes del refinamiento son mas cortos, con muchos aminoácidos comodines, sin zonas como [xxx] y con mayores valores de fitness, lo que indica patrones mas conservados y específicos. También, en los patrones devueltos, uno de los patrones antes del refinamiento es muy similar al que hemos definido (L-x-Y-x-S-x-R-x-G-L-x(3)-V-x-G-x-V), y el de mayor fitness encaja con la sección del logo que va de la columna 95 hasta la 119. Luego del refinamiento, el patrón de mayor fitness que encaja con esa misma sección tiene muchos menos comodines.

3d, 3e) Elegimos el patrón L-D-x-L-H-x(2)-L-x(3)-Y-x-G-M, y si bien encontramos muchos hits de guanylate cyclase, no se hallan resultados de Methyl-accepting chemotaxis protein.

Ejercicio 4 – De humanos a bacterias y viceversa

4a) BLAST: Realizamos blastp ingresando la secuencia de C. tetani, usando la base refSeq_select, añadiendo el organismo humano, usando BLOSUM45 y word size 3 para encontrar homologías lejanas. En los resultados no se halló la sGC. Blast permite recuperar homólogos bacterianos cercanos, pero no es un método efectivo para recuperar fácilmente la sGC humana, ya que la identidad de la secuencia entre bacterias y mamíferos puede ser baja aunque la estructura y la función estén conservadas.

PSI-BLAST: Esta herramienta construye un perfil evolutivo, detecta homología remota, y es más sensible que el blast común, por lo que podría funcionar. Sin embargo, hicimos el mismo procedimiento, y luego de 4 iteraciones la sGC sigue sin aparecer.

PFAM: Hacemos una búsqueda por secuencia en Interpro, luego en el resultado vamos a entries y filtramos por PFAM, seleccionamos HNOB y allí entramos a proteins y buscamos homo sapiens. Encontramos como resultado al guanilato ciclasa soluble subunidad beta-1.

PROSITE: Vamos a ScanProsite y seleccionamos la opción de escanear motivos, ingresamos el patrón definido en el ejercicio 3b y hallamos nuevamente al guanilato ciclasa soluble subunidad beta-1.

Consideramos mas rápido el método BLAST, ya que consiste en ingresar la secuencia con 2 parámetros, aunque es poco sensible. El método mas sensible es PFAM, ya que nos permite ver todas las proteínas que pertenecen al dominio de HNOB y los dominios relacionados a este.

Entre los dos métodos exitosos, creemos que PFAM fue mejor en este caso, ya que para PROSITE se tiene que conseguir un patrón, el cual sacamos del logo de HNOB en PFAM, mientras que en PFAM se ingresó la secuencia, y en unos pasos cortos se llegó al resultado.

4b) La proteína sGC se une a oxido nítrico para catalizar la reacción que convierte GMP a GMPc. GMPc es una molécula que actúa como segundo mensajero, participa en la transmisión de señales dentro de la célula. Cuando sGC esta activa, la concentración de GMPc aumenta considerablemente dentro de la célula., lo que provoca que el GMPc active mediante señales distintas proteínas específicas. En humanos, al parecer estos efectos producen relajación muscular y vaso dilatación.

En bacterias es diferente, las señalizaciones del GMPc pueden provocar efectos como modificar el comportamiento celular, entre otros distintos efectos.

Experimentos que podríamos proponer para estudiar al sGC podrían ser del tipo de mutagénesis dirigida sobre los genes implicados. Consiste en generar los aminoácidos implicados en la unión al hemo, por ejemplo la histidina conservada, luego comparar la actividad de estas bacterias mutadas con bacterias control en presencia y ausencia de óxido nítrico. De esta manera evaluamos niveles intracelulares de GMPc, cambios en el comportamiento (movilidad/quimiotaxis), o expresión de genes regulados por óxido nítrico. Si la proteína realmente funciona como un sensor de NO, esperamos que la silvestre responda al NO aumentando los niveles de GMPc y la mutante pierda total o parcialmente esta respuesta.