

Bioinformática 2026

TP N°3: Bases de datos secundarias

Objetivos:

- Familiarizarse con el uso de diferentes bases de datos secundarias de proteínas.
- Integrar los conceptos de diferentes firmas (signatures) de proteínas: patrones, perfiles y modelos ocultos de Markov (HMM).

Objetivo 1: Dominios en *Conserved domains* (NCBI)

Usted se encuentra trabajando con la bacteria que produce el tétanos, *Clostridium tetani* y ha clonado la siguiente secuencia:

>Protein X *Clostridium tetani*

```
MI FDNIAINANTVSNNGNRMKGTIVATWMRTCRKLYNDDVVNKAMSSVGWDSNKIFKPTENVEDSDLK
KVIEYIAKSEKLELGHLLWRQIGKDNLVSYNDFFPAFFQHENLYSFFNSLFDIHVVMTKKFPGAKPPLV
TIEPISSKEAIFYYESKRGMDYLLGAIEGSIKYFKEDIEIEELERTNESLKLKLKFQKNIYLLKKEFK
FNKLMSFGFVNLSAKIAISSFIISMISNLYISEARLYRTGVSSSLVQALIIFVICELLFKPKNFIKRE
LEKIKDHNYSKTKIVTKDFFEDIVEIINQNKD TVKKDFVSFKGVTDEMNTFVGNINKISDAMNYTSQ
GIAVVVEQVAETSVSQAQNTKTVFVLNGNIDSLRKIVDNENNNKIELECALDKVNNSYKNVDGTSKN
ILD TLDKFQEVKEKGQELQNRAEDITSIVSIVAQISEQTNLLALNASIDAALAGEQGKGFAVVAEEVR
NLAEQTKEAVEETNSSLVNFAKEIKNLSDKIDGQYEVLKNETKNLEIVRNISYEATTSIQSVASSMIY
TINDLNKEAESINNIFGNIESLATIAEENSASSEEV SASVSSYINEIRKLT DNINEFKKLTESFKAEL
CQYKI
```

Los ensayos bioquímicos muestran que esta proteína posee la absorbancia de una hemoproteína, y que está involucrada en quimiotaxis, y quizá en regular el estrés oxidativo/nitroxativo. Realice un BLAST para la secuencia en el NCBI (piense bien qué base de datos va a usar e indicarla en el informe). Analice los resultados:

1a) ¿Qué clase de proteínas encuentra? ¿Tienen algún grupo prostético? ¿Qué molécula unen y qué función tienen informadas?

2a) ¿Las de *C. tetani*, están poco o muy conservadas? ¿En qué otras especies aparecen homólogos? ¿Con qué grado de conservación?

Vaya a la solapa Graphical Summary y observe cuántos dominios son reconocidos. Haga *click* sobre ellos para obtener más información.

1b) ¿Cuántos dominios presenta la proteína según el NCBI-CDD? ¿De qué fuente se obtuvo cada uno de ellos? ¿Qué funciones tienen descritas?

Objetivo 2: InterPro y Pfam

InterPro es una base de datos integrada de anotación de proteínas que reúne información sobre familias proteicas, dominios y sitios funcionales a partir de múltiples bases de datos especializadas (como Pfam, PROSITE, etc). Su objetivo principal es clasificar proteínas y predecir su función mediante la identificación de firmas conservadas en las secuencias.

Vaya a la página web INTERPRO: <https://www.ebi.ac.uk/interpro/>. Busque por secuencia la proteína X de *Clostridium tetani*.

2a) En la solapa Overview ¿Qué dominios se encontraron para la proteína? ¿En qué bases de datos? ¿Son los mismos que los reportados por el NCBI-CDD?

Ahora analicemos únicamente los dominios reportados por Pfam (para ello vaya a la solapa Entries y seleccione Pfam como database). Haga *click* sobre el dominio HNOB. Esto lo dirige a una página donde hay información detallada sobre el dominio. Lea la descripción.

2b) Teniendo en cuenta la función de las proteínas de este dominio HNOB, indique qué aminoácido espera que esté muy conservado.

Analicemos entonces el alineamiento de las secuencias que originaron el HMM del dominio. En el Menú de la izquierda seleccione *Alignment*, y luego, entre las opciones, *Seed*. Observe el alineamiento múltiple.

2c) ¿Encuentra el aminoácido muy conservado del punto 2b?

2d) Busque 3 columnas MUY conservadas, 2 poco conservadas y 2 presencias de GAPS/INSERCCIONES.

Ahora seleccione en el Menú *Profile HMM*. Analice el logo y busque las columnas anotadas anteriormente.

2e) ¿Coincide su apreciación del AlinMult con la información del logo? Determine los aminoácidos más importantes de acuerdo a su altura en el logo, y anote cuál o cuáles son los tipos de aminoácidos más

representados en esas posiciones. Determine ahora las 3 posiciones con mayor probabilidad de inserción.

2f) Identifique al aminoácido del punto 2b. ¿Qué número de posición tiene?

Descargue e inspeccione el modelo HMM en formato texto. Identifique las 3 filas de valores que hay para cada punto de la matriz posición/aminoácido del modelo.

2g) ¿Qué valores de emisión tiene la posición del punto 2b para los distintos aminoácidos? ¿Es lo que esperaba? Busque también los valores de las otras posiciones identificadas como conservadas y concluya sobre cómo están expresados esos valores.

Seleccione ahora en el MENU "*Domain-Architectures*"

2h) ¿Con qué otros dominios se puede combinar HNOB para formar proteínas multidominio? Busque la organización de dominios que corresponde a la proteína de *C. tetani*.

PFAM permite también buscar secuencias de proteínas que contienen un mismo dominio en distintos organismos. Dentro de la página de PFAM del dominio HNOB vaya al Menú "Taxonomy" y visualice con *Weight Segments* por número de especies.

2i) Localice a *Clostridium*. ¿Cuál es su número de secuencias y de especies? Vaya al modo tabla e indique algunas otras especies de *Clostridium* que contengan el dominio HNOB.

Finalmente haga *click* ahora en el otro dominio encontrado por Pfam para esta proteína (MCPsignal) y vea la entrada de PFAM. Identifique los datos más relevantes.

Objetivo 3: Prosite y patrones

PROSITE es una base de datos especializada en la identificación de motivos y patrones conservados en proteínas que están asociados con funciones biológicas específicas. Estos motivos representan regiones cortas de secuencia que suelen corresponder a sitios activos, sitios de unión a ligandos o regiones funcionales importantes dentro de una proteína. PROSITE describe estas firmas mediante patrones (patterns) y perfiles (profiles), que permiten detectar dichas regiones conservadas al comparar una secuencia proteica con el contenido de la base de datos. Vaya a <http://prosite.expasy.org/> y verá varios MENUS con distintas posibilidades.

Escanee la proteína con la herramienta *Quick Scan mode of ScanProsite* pegando la secuencia en estudio en formato FASTA en la ventana indicada. Analice el resultado encontrado clickeando sobre el motivo encontrado (PS50111).

3a) ¿Qué tipo de *signature* encuentra? ¿Un patrón formado por expresiones regulares (*pattern*) o un perfil formado por una matriz de frecuencias? ¿A qué dominio corresponde? ¿HNOB o MCPsignal? Ayudese evaluando el logo de la secuencia correspondiente.

PROSITE también nos permite buscar en bases de datos de proteínas, todas aquellas secuencias que tengan un patrón definido. El patrón utilizado en la búsqueda puede ser uno de los ya existentes en PROSITE o uno construido por el usuario. Para construir un patrón puede hacerlo a mano o utilizar la herramienta PRATT de PROSITE a partir de un grupo de secuencias o un alineamiento múltiple de ellas.

Construcción del patrón a mano:

A partir de la información del HMM logo y el AlinMult de PFAM del dominio HNOB, construya un patrón de entre 5-10 posiciones a mano. Utilice este patrón para buscar en la base de datos de secuencias de PROSITE. Para esto en la página principal de PROSITE hay que ir al *link Scan-Prosite*. Una vez abierto este link seleccionar “*Option 2 - Submit MOTIFS to scan them against a PROTEIN sequence database*”. Escribir el patrón en el campo correspondiente y comenzar la búsqueda.

3b) Analice qué tipo de proteínas es capaz de encontrar. ¿Qué le parece el resultado?

Construcción del patrón con PRATT:

Acceda a PRATT desde el cuadro “*Other Tools*” de la página principal de PROSITE. PRATT le permite cargar una serie de secuencias o un alineamiento en forma FASTA, y generar posibles patrones. Para obtener un buen *set* de secuencias para construir el patrón se recomienda usar las secuencias correspondientes al seed del dominio HNOB en PFAM. Para obtener estas secuencias vaya a la página de HNOB de PFAM. Una vez allí seleccione *Alignments*, elija Seed y descargue el archivo. Este alineamiento está en un formato llamado Stockholm (inspeccionelo), pero para usar PRATT necesitamos convertirlo a un alineamiento en formato fasta. Averigüe cómo hacerlo con AlignIO en Biopython.

Una vez tenga el alineamiento en formato fasta, peguelo en PRATT indicando que es un alineamiento. PRATT permite variar ciertos parámetros en la búsqueda de patrones. Es recomendable establecer el parámetro % de secuencias en las que se verifica el patrón (“*The pattern must match at least*”) dentro del rango 50-70%. Esto da usualmente buenos resultados. Para proteínas con patrones débiles como HNOB también puede ser conveniente aumentar el

número máximo de *wildcards* aceptados en el patrón (“*max number of wildcards*”). Establecer este parámetro en un valor de 8. Antes de iniciar la búsqueda tilde el casillero “*View PRATT output file*”.

3c) Analice la salida de PRATT. Compare los patrones antes y después del refinamiento. Ahora compare esos patrones con el HMM logo de PFAM. ¿Es capaz de localizarlos?

3d) Elija un patrón y úselo en PROSITE para buscar en las bases de datos. Analice los resultados en comparación con el caso anterior del patrón creado a mano. Busque entre los resultados la presencia de “*Methyl-accepting chemotaxis protein*”, “*NO binding*” o algún nombre de proteína que sugiera la unión de NO. También busque en los resultados la función “*guanylate cyclase*” (comprenderá la razón de esto en el próximo ejercicio).

Para hacer más específica la búsqueda en PROSITE se recomienda combinar con el operador AND dos o más patrones distintos. Esto le permitirá encontrar resultados más relacionados con nuestra búsqueda. Si no encuentra nada significativo en la base de datos *SwissProt*, seleccione la base de datos TrEMBL. Esta base de datos tiene muchas más secuencias, pero la búsqueda puede tardar mucho más.

3e) ¿Logró encontrar los resultados que esperaba?

Objetivo 4: de humanos a bacterias y viceversa

En humanos existe una proteína llamada guanilato ciclasa soluble (sGC) que cataliza la transformación de GMP a GMPc, en diferentes vías de señalización celular. La más importante tal vez sea la que produce la vasodilatación del endotelio. La señal que activa la sGC es una molécula pequeña muy reactiva denominada óxido nítrico (NO). El NO es capaz de activar la sGC al unirse al grupo hemo (que posee la proteína) y producir un cambio conformacional que aumenta la actividad enzimática unas 400 veces. Comprender el mecanismo de activación de la sGC es un problema de sumo interés para los fisiólogos (por su rol en el control del sistema circulatorio), para los biólogos estructurales (porque es una proteína alostérica muy particular) y para los químicos inorgánicos (depende de la reactividad y coordinación del NO al hierro de un grupo hemo).

Uno de los pasos fundamentales para comprender el funcionamiento de una proteína es conocer su estructura. Lamentablemente, si bien se persigue la obtención de la estructura de la sGC desde hace más de 15 años, ¡la misma se rehúsa a cristalizar! A pesar de la negativa a cristalizar, los interesados en el tema incorporaron al estudio de esta proteína a los bioinformáticos allá por el año 2003, quienes entre otras cosas descubrieron una proteína homóloga al dominio de activación (el que posee al hemo y une al NO) de la sGC en una bacteria termófila. Esta proteína fue clonada y caracterizada y se mostró que es una hemoproteína capaz de unir NO como el dominio de activación de la sGC. Además la proteína fue cristalizada, permitiendo un avance

significativo en la comprensión del mecanismo de la sGC. Al dominio de activación de la sGC, y que caracteriza a numerosas proteínas de bacterias, se lo conoce como HNOB y es el que usted estuvo estudiando.

Suponga ahora que lo mencionado anteriormente no ocurrió, pero usted sospecha que su proteína, que posee una homóloga en una bacteria termófila de estructura conocida, posee un homólogo no caracterizado o desconocido en mamíferos (más precisamente humanos) ¿Sería usted capaz de encontrarlo?

4a) Partiendo de la secuencia de *C. tetani*, intente descubrir una proteína homóloga en humanos (idealmente la sGC) usando a) BLAST, b) PSI-BLAST, c) PFAM y d) PROSITE. Describa cómo procedió en cada caso, y si llegó al resultado deseado ¿Cuál es el método más sensible? ¿Cuál es el más rápido?

4b) A partir de toda la información obtenida en el TP, escriba un párrafo sobre la posible función de la proteína y proponga algún experimento para estudiarla.