

TP N°4: Minería de Datos y Modelos Ocultos de Markov

Parte 1 - Introducción a HMMs aplicada a dominios Globina

Objetivos Generales. En este módulo utilizaremos por línea de comando dos programas muy utilizados en bioinformática, MAFFT para hacer alineamientos múltiples y HMMER para trabajar con Modelos Ocultos de Markov (HMM del inglés, Hidden Markov Model). El objetivo general es poder utilizar estos programas para realizar nuestro propio HMM y MSA (del inglés Multiple Sequence Alignment) de un grupo de proteínas de interés y realizar la búsqueda de todas las secuencias que componen nuestro grupo en una dada base de datos. Además aprenderemos a definir los umbrales, y analizar la capacidad de nuestro modelo en cuanto a sensibilidad y especificidad.

Los objetivos específicos son:

- i) Instalación y uso de HMMER y MAFFT por línea de comando.
- ii) *Parseo* de salidas de HMMER.
- iii) Construcción de histogramas de puntaje.

Para empezar, contemos una pequeña historia... *“Su jefe tiene un set de casi 38 mil secuencias de dominios de proteínas de las 3 grandes familias de globinas, pero accidentalmente borró la única copia del archivo fasta con dichas secuencias. Afortunadamente, su jefe dispone de otro archivo con las secuencias completas de las proteínas (es decir, no solo el dominio globina sino otros dominios que tuviera la secuencia completa también). Sin embargo, su jefe le dice que existe un modo fácil de recuperar los dominios globina de cada familia, y eso es a través de la minería de datos de secuencias utilizando HMMs. Su jefe le pide que primero empiece por separar las proteínas de la familia de las protoglobinas, para lo cual debe descargar un subconjunto de secuencias llamado “seed” o “semilla” de la base de datos Pfam correspondiente a la familia “Protoglobin”. Con estas secuencias puede crear un MSA (alineamiento múltiple de secuencias, o Multiple Sequence Alignment), con el cual generar un HMM y realizar la minería de datos sobre el total de secuencias completas de globinas, y recuperar con eficiencia la gran parte de los dominios globina de la familia protoglobina....”*

Objetivo 1: instalar y correr MAFFT y HMMER

1a) Instalar MAFFT y HMMER

En primer lugar necesitará instalar algunos programas. Éstos son MAFFT, para el MSA, y HMMER para generar HMMs y realizar minería de datos.

```
sudo apt-get install mafft
sudo apt-get install hmmer
```

1b) Obtener conjunto de secuencias “semilla”

Si usted recuerda cómo se utilizan los HMM en el contexto de Bases de Datos Secundarias, recordará que debemos ser capaces de: i) resolver el problema de scoring, ii) resolver el problema de alineamiento y iii) resolver el problema de entrenamiento. Además recordará que el punto de partida para construir un HMM es tener un conjunto de secuencias “semilla”. En este trabajo utilizaremos como punto de partida el *seed* que se bajan de PFAM (cosa que por obvias razones suele ser siempre una buena idea).

Entonces, vaya a Interpro y busque “**protoglobin**”. Ingrese a a entradas de Pfam y una vez allí seleccione Alignments, elija Seed y descargue el archivo. Este alineamiento está en un formato llamado Stockholm (inspeccionelo), pero para usar PRATT necesitamos convertirlo a un alineamiento en formato fasta. Averigüe cómo hacerlo con AlignIO en Biopython.

1c) Realizar el MSA con MAFFT. Una vez se tienen las secuencias *seed* hay que alinearlas. Para ello se usará el programa MAFFT mediante un comando de este estilo:

```
mafft seed.fasta > seed_msa.fasta
```

Como resultado, MAFFT le devolvió sus secuencias alineadas en formato fasta (pero usted puede elegir otro formato de salida también). Si lo desea puede visualizar las secuencias alineadas en MSA (e incluso editar el MSA) con un visualizador de alineamientos como **Jalview** (puede instalarlo con “sudo apt-get install” como hizo con MAFFT y HMMER pero se descarga una versión vieja, si lo baja del sitio web puede obtener la más nueva para cualquier sistema operativo <http://www.jalview.org/getdown/release/#>).

1d) Crear el HMM. Ahora que dispone de un *seed* alineado en un MSA puede crear un HMM con él. Para ello usará una de las herramientas que dispone HMMER: *hmmbuild*. Esta herramienta funciona con un comando de este formato:

```
hmmbuild secuencias_modelo.hmm seed_msa.fasta
```

El archivo “secuencias_modelo.hmm” (o el nombre que le haya puesto) es un archivo de texto que contiene las probabilidades que hacen al HMM en cuestión. Este archivo, junto con las secuencias target, le permitirán realizar la minería de datos.

Ejercicio 1a-d: corra todos los comandos anteriores y analice un poco el archivo “secuencias_modelo.hmm”, puede identificar en él los parámetros que usted conoce debe poseer el modelo (probabilidad de emisión de cada residuo en cada columna (estado match), columnas importantes, probabilidad de inserción, etc).

1e) Realizar Minería de datos usando HMM.

Para hacer esto recurriremos a otra herramienta de HMMER llamada *hmmsearch*, y utilizaremos como conjunto sobre el cual realizar la búsqueda (o sea la base de datos) un archivo local “globin_full_sequences.fasta” (que lo encontrará en el campus). Hagamos entonces el *hmmsearch*:

```
hmmsearch secuencias_modelo.hmm globin_full_sequences.fasta > busqueda.out
```

Por default, *hmmsearch* le devuelve un archivo de texto con una larga tabla de resultados. Cada fila corresponde a una de las secuencias evaluadas con el HMM, y se indica el puntaje y *e-value* globales de la secuencia, el puntaje y *e-value* correspondientes al dominio mejor puntuado, la cantidad de “dominios” detectados en esa secuencia (es decir, cuántas veces el HMM “alineó” contra la secuencia), nombre y descripción de la secuencia (si la hubiera).

Puntaje y e-value de la secuencia completa			Puntaje y e-value del dominio mejor puntuado			Numero de dominios detectados		Nombre de secuencia	Descripcion
E-value	score	bias	E-value	score	bias	exp	N	Sequence	Description
1.1e-58	195.9	0.0	1.4e-58	195.6	0.0	1.1	1	tr A0A3N4HU81 A0A3N4HU81_ASCIM	Uncharacterized protein OS=Ascob
1.9e-58	195.2	0.1	2.4e-58	194.9	0.1	1.1	1	tr A0A057E174 A0A057E174_9EURO	Uncharacterized protein OS=Asper
1.6e-56	189.0	0.0	2.3e-54	181.9	0.0	2.1	2	tr R1G831 R1G831_BOTPV	Putative globin-like protein OS=
7.1e-56	186.8	0.0	8.6e-56	186.6	0.0	1.1	1	tr A0A2V1DEL3 A0A2V1DEL3_9PLEO	Uncharacterized protein OS=Peric
3.7e-55	184.5	0.2	4.6e-55	184.2	0.2	1.1	1	tr A0A084G1V7 A0A084G1V7_9PEZI	Uncharacterized protein OS=Scedo
4.3e-55	184.3	0.0	5.2e-55	184.0	0.0	1.1	1	tr A0A370JGP1 A0A370JGP1_VENIN	Uncharacterized protein OS=Ventu
7.9e-55	183.4	0.0	9.8e-55	183.1	0.0	1.1	1	tr A0A167N2P2 A0A167N2P2_9PEZI	Globin OS=Sporothrix insectorum
5.1e-53	177.5	0.3	6.8e-53	177.1	0.3	1.2	1	tr A0A318Z1H1 A0A318Z1H1_9EURO	Uncharacterized protein OS=Asper

Además, luego de esa tabla, se profundiza en detalles de cada secuencia analizada (tiene que “scrollear” el archivo hasta que la tabla termina).

Puntaje de dominios		inicio y fin de alineamiento con el HMM		inicio y fin de alineamiento del dominio	
Secuencia	#	score	bias	c-Evalue	i-Evalue
tr R1G831 R1G831_BOTPV	1	?	5.3	0.0	2.5
tr R1G831 R1G831_BOTPV	2	!	181.9	0.0	1.1e-54
Alignments for each domain:					
== domain 1 score: 5.3 bits; conditional E-value: 2.5					
seed 2 earlayllsflgteedlaalralap 27					
ear++yl+ fl+++ aa + a					
tr R1G831 R1G831_BOTPV 24 EARIQYLHTFLDFSSTASARSNRAR 49					
89*****998887666555 PP					
== domain 2 score: 181.9 bits; conditional E-value: 1.1e-54					
seed 13 glteedlaalralapliealipavdafveklisfpetarifet.....ssqierlkdfklsyllklfsgpfdsay 83					
++ d++aL+ ++l+allpa+v+++Y+kl+++tar+fet s+ql ++k+fl++yl +l+s+p++++					
tr R1G831 R1G831_BOTPV 65 RVQKGDI EALQTGHKVIKALIPAINIVYVKLLQYDITARAFETrstsfegpmdavpdenSPQIHRKMFRLRAYLRLCSDPSKMEF 151					
56788*****998887666555 PP					
seed 84 veyldkvGkmht.....rlgleprwyiaalglvgevilleallekeklksaaektalvkalnKliwldndlaleaVvreege 158					
+eyldkvG+mh+ +l++e+++ a+l+++q+vl ea+l++++l+ +k+alvkal K+lw++ndl++++Yvr+g+e					
tr R1G831 R1G831_BOTPV 152 WEYLDKVGMMHVgrgrqhPLHVEYMHIGALLSFIDVLNEAILSHPRLHMNRKIALVKALGKVIWQNDLFAKWYVRDGE 232					
*****986 PP					

En esta sección, para cada secuencia se muestra una lista de todos los dominios detectados con sus respectivos puntajes en que alinean el HMM y la secuencia, seguido de los alineamientos correspondientes.

Nota: en realidad uno buscaría sobre toda una base de datos (como Uniprot, Pfam o PDB) o el proteoma de algún organismo, pero como eso tarda mucho (y arriesgan quemar sus compus) vamos a usar un conjunto más pequeño ya disponible. De todos modos, si usted lo desea puede descargar todo Uniprot de la página web en formato fasta y correr HMMsearch contra esta (pero cuidado, Uniprot pesa más de 60Gb). Otra alternativa es correr HMMER en el server: <https://www.ebi.ac.uk/Tools/hmmer/search/hmmsearch>

Ejercicio 1e: analice el archivo de salida de HMMsearch, trate de identificar dónde están los resultados obtenidos para cada secuencia query, y de ellos donde está el E-value, la cobertura, etc.

Objetivo 2: Recuperar los dominios con Python

Si a esta altura usted está aburrido con esta unidad y tiene ganas de programar, no se preocupe, ahora viene lo divertido.

2a) Histograma de puntajes de dominio. El primer objetivo busca implementar un script en python que grafique un histograma de puntajes de secuencia POR DOMINIO (recuerde, usted le interesa recuperar los dominios globina, no la secuencia entera de cada proteína), a partir de la salida de *hmmsearch*. Necesitará una librería para graficar cómo matplotlib y la librería de biopython SearchIO, para poder parsear el archivo salida de *hmmsearch*.

Les dejamos una ayudita con “pseudo-código” para empezar:

```
from Bio import SearchIO
import matplotlib.pyplot as plt

resultados=list(SearchIO.read('busqueda.out', 'hmmer3-text'))
Ahora usted debe:
Iterar secuencias (análogo a los hits de Blast)
    Iterar dominios detectados (análogo a los HSP de Blast)
        Añadir puntaje de dominio a lista
```

Para hacer el histograma y grabar/mostrar la figura puede utilizar los siguientes comandos:

```
histogram=plt.hist(puntajes_lista, bins=numero_de_bins)
plt.savefig(nombreFigura)
plt.show()
```

2b) Determinación de puntaje de corte y extracción del archivo de los dominios de interés. Con el gráfico que hizo mediante su script, establezca (a ojo) un puntaje de corte para recuperar los dominios de secuencia que estén por encima de dicho corte. Recuerde que el puntaje de corte es aquel valor tal que aquellas secuencias que cuando sean contrastadas contra el HMM den un valor superior al valor de corte elegido, serán consideradas como miembros de la familia/dominio/grupo que usted está analizando.

Ejercicio 2b: Desarrolle en python un código que utilice el puntaje de corte recién establecido (esto debe ser un parámetro) para extraer los dominios buscados en las secuencias correspondientes. El mismo debe devolver un archivo fasta con dichas secuencias recortadas. El código debe tener además las dos siguientes funciones:

i) Debe ser capaz de obtener los Uniprot IDs y las posiciones de inicio y fin de los dominios y entregar los resultados como lista de listas (o una matriz de numpy o pandas),

ii) Tomar los valores de la lista anterior (IDs y posiciones), y usarlos para cortar las secuencias del registro fasta original.

Nota: Para aquellos que lo deseen, a continuación les damos un poco de ayuda con el código. Los nombres de las secuencias en el archivo de salida debe ser de este formato: P04569/3-154 (que es el formato que tienen las secuencias en la base de datos Pfam). Lo primero ("P04569") es el identificador de la secuencia en la base de datos Uniprot, lo segundo ("3-154") son las posiciones de inicio y fin del dominio en la secuencia completa.

Uniprot IDs y posiciones (ejemplo):

```
A0A0U1M3Y2 39 219
A0A1Y1ZMR4 20 200
F7VKQ0 27 207
A0A2L2TID2 17 197
A0A1Q8S944 18 198
A0A096PC56 17 197
```

Del formato de Uniprot al formato de Pfam:

tr F7VKQ0 F7VKQ0_SORMK	F7VKQ0/3-158
sp P02144 MYG_HUMAN	P02144/6-245
tr A0A2L2TID2 A0A2L2TID2_9HYPO	A0A2L2TID2/1-144

Aclaración: "tr" es por "TrEMBL (secuencias no curadas de Uniprot) y "sp" por Swissprot (secuencias curadas).

Un poco de pseudocódigo de ayuda:

```
from Bio import SeqIO
```

```
Def extraerPosiciones(puntaje_corte):
```

```
    lista de límites
```

```
    searchFile=list(SearchIO.read("resultado_hmmsearch", 'hmmer3-text'))
```

```
    Iterar secuencias
```

```
        Iterar dominios en secuencia
```

```
            Si dominio.puntaje > puntaje_corte
```

```
                añadir id y limites a lista de limites
```

```
    Devolver lista de limites
```

```
Def guardarDominios(lista_limites):
```

```
    fasta=list(SeqIO.parse("globin_full_sequences.fasta", 'fasta'))
```

```
    Iterar Fasta
```

```
        Iterar lista_limites
```

```
            Si hay coincidencia modificar el ID de la secuencia y la secuencia misma
```

Guardar el registro modificado en una nueva lista
`SeqIO.write(registros_modificados, "salida.fasta", "fasta")`

Sugerencias: itere lista_límites con un ciclo “while” utilizando un contador para indexar los elementos visitados. Cuando “matchee” la secuencia en el archivo fasta con el elemento de la lista de límites, elimine el elemento de la lista de límites (ya no lo necesitará más) y resetee el contador. De este modo la lista de límites se hará cada vez más chica con cada coincidencia que logre, recortando así el tiempo de cómputo.

```
Iterar fasta
contador=0
Mientras no haya coincidencia y contador<len(lista_límites):
    Si coincidencia:
        Modificar el registro
    Si len(lista_límites)>1:
        lista_límites.pop(contador)
    Si no: contador+=1
```

Ejercicio 2c. Responda:

- ¿Cuántos dominios de protoglobina logró recuperar de la minería de datos?
- ¿Puede afirmar que recuperó todos y que no dejó alguno afuera?
- ¿O que solo recuperó dominios protoglobina y que no incorporó dominios globina de otro tipo? ¿Por qué?

Objetivo 3: comparar y analizar alineamientos

3a) Alinear los dominios.

Ahora lo que vamos a hacer es utilizar HMMer para alinear y comparar con el alineamiento que haga MAFFT. El comando para correr *hmmalign* es del tipo:

```
hmmalign -o alin_seqs.sto secuencias_modelo.hmm dominios.fasta
```

El comando para alinear con MAFFT ya lo conoce!

Ejercicio 3a) Parsee los MSAs hechos con *hmmalign* y MAFFT y busque la posición de la histidina F8 (el residuo más conservado y característico de todas las globinas), y calcule la proporción de gaps en el MSA para esa posición (sugerencia: busque una columna en el MSA donde la histidina representa más del 80% de los aminoácidos presentes en esa columna).

Compare el porcentaje de histidinas en esa columna entre los dos MSAs obtenidos (por MAFFT y *hmmalign*), y la proporción de gaps obtenida. ¿En qué posición está la histidina F8

en cada MSA? ¿Está en la misma posición en ambos casos? ¿En cuál MSA hay más presencia de gaps?


Para aquellos que lo deseen, les dejamos una ayudita (usando pandas y Bio.AlignIO):

```
align = AlignIO.read("alineamiento", "formato(fasta/stockholm/phylip..")
align_pd=pd.DataFrame(align) #convierte el alineamiento en un pandas dataframe
align_pd[k].value_counts() #devuelve un listado de cantidad de veces que aparecen
los elementos de una columna k
align_pd[k].value_counts().index #devuelve lista con los elementos que hay en esa
columna k
align_pd[k].value_counts()["H"] #devuelve la cantidad de veces que aparece el
elemento "H" (por histidina) en la columna k (si es que hay un elemento "H", si no tira error)
align_pd.shape #devuelve tupla con las dimensiones del dataframe (filas x columnas)
```

Ejercicio 3b. Minería de datos.

PFAM posee en su base de datos 3 dominios globina, el ya utilizado protoglobina, y los denominados "Globin" y "Bac_globin".

1) Descargue los *seeds* de éstas dos familias de globinas en Pfam, genere los HMM y corra *hmmsearch* con cada HMM nuevo contra el set de globinas.




2) Genere los histogramas de puntaje de dominio y establezca un umbral de corte para luego extraer los dominios.

3) Compare los 3 sets obtenidos. ¿Hay alguna secuencia presente en más de un set? (use los Uniprot ID de las secuencias para buscar coincidencias entre los sets)

Ejercicio 3c) Corra cada HMM contra cada set de dominios obtenidos (si son 3 HMM y 3 sets de dominios recuperados, son un total de 9 corridas de *hmmsearch*).

Ejercicio 3d) Usando los resultados de la búsqueda realizada anteriormente genere histogramas de distribución de puntaje para cada HMM (para cada set de secuencias use un color distinto). A modo de ejemplo:



¿Observa algún solapamiento entre las curvas? ¿Cómo lo interpretaría? ¿Fue buena la separación que hizo?